

Musicon

Generarea de playlist-uri Spotify bazate pe mood
folosind Machine Learning și Reinforcement Learning

Badescu Bianca-Mădălina

Universitatea de Vest din Timișoara

Facultatea de Informatică

Disciplina: Inteligență Artificială

31 mai 2026

Cuprins

1	Introducere	3
2	State of the Art	3
2.1	Modelul circumplex al afectului	3
2.2	Clasificarea emoțiilor în muzică	3
2.3	Sisteme de recomandare muzicală	4
2.4	Analiza sistemelor existente	4
2.4.1	Moodify (Sabriweiss, 2026)	4
2.4.2	Moodify (Orzanai, 2023)	4
2.4.3	Comparație cu Musicon	5
3	Arhitectura Aplicației	5
3.1	Structura proiectului	6
3.2	Configurația centrală	6
4	Componenta de Machine Learning	6
4.1	Dataset și preprocesare	6
4.1.1	Sursa datelor	6
4.1.2	Distribuția mood-urilor	6
4.1.3	Normalizare	7
4.1.4	Împărțirea train/test	7
4.2	Clasificare	7
4.2.1	Modele antrenate	7
4.2.2	Rezultate	8
4.2.3	Metrici per clasă	8
4.2.4	Analiza acurateții ridicate	8
4.3	Comparația supervizat vs. nesupervizat	8
5	Componenta de Reinforcement Learning	9
5.1	Formularea MDP	9
5.1.1	Spațiul stărilor	9
5.1.2	Spațiul acțiunilor	9
5.1.3	Funcția de recompensă	9
5.2	Antrenarea Q-Learning	9
5.3	Învățare online prin feedback-ul utilizatorului	10
6	Integrarea componentelor și Interfața	10
6.1	Integrarea cu Spotify	10
7	Concluzii și direcții viitoare	10
8	Bibliografie	10

1 Introducere

Platformele de streaming precum Spotify oferă acces la milioane de piese, dar descoperirea muzicii relevante pentru starea emoțională curentă a utilizatorului rămâne o problemă semnificativă. Sistemele de recomandare actuale se bazează pe istoricul de ascultare și pe filtrarea colaborativă și nu ia în considerare ce sentimente transmit melodiile și cum se pot corela acestea într-un playlist.

Proiectul **Musicon** abordează această problemă prin dezvoltarea unui sistem de generare automată a playlist-urilor bazat pe identificarea stării emoționale. Sistemul combină două paradigme fundamentale ale Inteligenței Artificiale:

- **Machine Learning** (învățare supervizată) pentru clasificarea pieselor în funcție de mood, folosind caracteristici audio extrase din Spotify;
- **Reinforcement Learning** (învățare prin recompensă) pentru optimizarea selecției secvențiale a pieselor în playlist.

Obiectivele principale ale proiectului:

1. Construirea unui dataset potrivit prin utilizarea a 10.000 de piese populare etichetate cu 8 stări emoționale diversificate.
2. Antrenarea și compararea a 3 clasificatori ML (Decision Tree, Random Forest, K-Nearest Neighbors) pentru predicția mood-ului pe baza feature-urilor audio Spotify.
3. Implementarea unui agent Q-Learning care modelează selecția pieselor ca un proces decizional Markovian (MDP) cu 192 de stări și 10 acțiuni.
4. Dezvoltarea unei interfețe web interactive folosind Streamlit, care permite utilizatorilor să selecteze un mood prin 24 de preset-uri sau prin text liber.

2 State of the Art

2.1 Modelul circumplex al afectului

Fundamentul teoretic al mapării emoționale în Musicon este **Modelul Circumplex al Afectului**, propus de James A. Russell în 1980 [1]. Acest model reprezintă stările emoționale ca puncte într-un spațiu bidimensional, având ca axe **valența** (plăcut – neplăcut) și **activarea** (energie scăzută – energie ridicată).

În contextul muzical, valența corespunde caracterului pozitiv sau negativ al unei piese (măsurat prin feature-ul Spotify *valence*), iar activarea corespunde intensității percepționale (măsurată prin *energy*).

2.2 Clasificarea emoțiilor în muzică

Thayer [2] a propus un model de clasificare în 4 cadrane bazat pe Modelul Circumplex al Afectului propus de Russell:

- **Energie ridicată, valență pozitivă** – Exuberant, entuziast
- **Energie ridicată, valență negativă** – Anxios, furios

- **Energie scăzută, valență pozitivă** – Calm, relaxat
- **Energie scăzută, valență negativă** – Melancolic, trist

Musicon extinde această clasificare la **8 stări emoționale**, oferind o arie mai extinsă de stări: *melancholic, dark, calm, nostalgic, romantic, happy, euphoric, energetic*.

2.3 Sisteme de recomandare muzicală

Sistemele de recomandare muzicală se împart în 3 categorii principale [10]:

1. **Filtrare colaborativă** – recomandă piese ascultate de utilizatori similari (Last.fm, Pandora);
2. **Filtrare bazată pe conținut** – utilizează caracteristici audio pentru a găsi piese similare;
3. **Abordări hibride** – combină cele două metode.

Musicon adoptă o abordare bazată pe conținut, folosind feature-uri audio Spotify și tehnici de ML/RL.

2.4 Analiza sistemelor existente

2.4.1 Moodify (Sabriweiss, 2026)

Moodify [11] este un sistem hibrid de recomandare muzicală dezvoltat în Python cu Streamlit [6], care combină procesarea limbajului natural (NLP), învățarea nesupervizată și filtrarea bazată pe conținut. Principalele caracteristici:

- **Detecție mood:** 4 mood-uri (Happy, Sad, Calm, Energetic) prin selecție directă sau clasificare NLP cu **Logistic Regression** pe text liber (CountVectorizer)
- **Clasificare:** Algoritm *rule-based* pe feature-uri audio (valence, energy, tempo) și **K-Means Clustering** cu 8 clustere
- **Recomandare:** Filtrare bazată pe conținut folosind **Euclidean distance** între profilul utilizatorului și piesele din dataset
- **Personalizare:** Construirea unui profil de gust pe baza pieselor salvate de utilizator
- **Feature-uri:** 6 feature-uri audio Spotify (energy, valence, tempo, danceability, acousticness, instrumentalness)

2.4.2 Moodify (Orzanai, 2023)

O altă variantă Moodify [12] utilizează modelul **LightGBM** pentru clasificarea emoțiilor pieselor și cosine similarity pentru recomandare. Se bazează pe **modelul Thayer** cu 4 emoții (happiness, sadness, calmness, energy) și folosește un dataset construit prin principiul “Wisdom of Crowds” din playlist-uri Spotify. Alte implementări similare includ varianta Moodify de pe Devpost [?] și extensia Chrome Moodify AI [?], ambele axate pe generarea de playlist-uri bazate pe mood.

2.4.3 Comparație cu Musicon

Tabela 1: Comparație Musicon cu sisteme existente

Caracteristică	Musicon	Moodify (Sabriweiss)	Moodify (Orzanai)
Mood-uri	8	4	4
Clasificator ML	DT/RF/KNN	LogReg+KMeans	LightGBM
Reinforcement Learning	Da (Q-Learning)	Nu	Nu
Metrică similaritate	Cosine	Euclidean	Cosine
Feature-uri audio	8	6	8
Personalizare Spotify	Da	Parțial	Nu
Interfață	Streamlit	Streamlit	Streamlit
Preset-uri mood	24	4	–

Caracteristici cheie ale Musicon:

1. **Clasificare extinsă (8 mood-uri)** – față de cele 4 mood-uri standard din Thayer
2. **Reinforcement Learning** – singurul sistem care folosește Q-Learning pentru optimizarea secvențială a playlist-ului;
3. **Compară 3 clasificatori ML** – evaluare sistematică a Decision Tree, Random Forest și KNN
4. **Integrare Spotify** – fuziunea profilului utilizatorului cu cel al preset-ului pentru recomandări personalizate

3 Arhitectura Aplicației

Aplicația urmează o arhitectură modulară cu un flux secvențial clar (Figura 1).




Figura 1: Arhitectura pipeline-ului Musicon cu integrare Spotify

3.1 Structura proiectului

```
1 Musicon/  
2   config.py           % Configuratie centrala  
3   preprocess.py       % Preprocesare date  
4   train.py            % Antrenare modele ML  
5   q_learning.py       % Antrenare agent RL  
6   recommender.py      % Generare playlist-uri  
7   streamlit_app.py    % Interfata web  
8   notebooks/          % Jupyter notebooks (EDA, ML, RL)  
9   data/  
10      raw/             % Dataset original  
11      processed/       % Train/test split + scaler  
12   models/            % Modele antrenate (.pkl, .npy)  
13   results/           % Plot-uri si vizualizari
```

Listing 1: Structura fisierelor proiectului

3.2 Configurația centrală

Toate constantele proiectului sunt definite în `config.py`: căile către fișiere, lista de feature-uri audio, cele 8 mood-uri cu codurile lor numerice, 24 de preset-uri de mood cu profiluri audio, setările ML și parametrii RL.

4 Componenta de Machine Learning

4.1 Dataset și preprocesare

4.1.1 Sursa datelor

Datasetul utilizat este `popular_10k_mood_labeled.csv`, conținând **10.000 de piese** agregate din multiple surse Spotify. Fiecare piesă are 19 coloane, dintre care 8 reprezintă feature-uri audio relevante:

Tabela 2: Feature-uri audio Spotify utilizate

Feature	Descriere	Domeniu
danceability	Potrivirea pentru dans	[0, 1]
energy	Intensitate perceptuală	[0, 1]
loudness	Volum general (dB)	[−38.5, 1.0]
speechiness	Prezența cuvintelor vorbite	[0, 1]
acousticness	Încredere că piesa e acustică	[0, 1]
instrumentalness	Absență vocală	[0, 1]
valence	Pozitivitate muzicală	[0, 1]
tempo	Bătăi pe minut (BPM)	[0, 209]

4.1.2 Distribuția mood-urilor

Datasetul folosește **8 categorii de mood** ordonate de-a lungul spectrului valență–energie:

Tabela 3: Distribuția claselor de mood în dataset

Cod	Mood	Număr piese
0	melancholic	867
1	dark	520
2	calm	246
3	nostalgic	790
4	romantic	117
5	happy	2 951
6	euphoric	1 919
7	energetic	2 590
Total		10 000

Se observă un **dezechilibru de clasă** semnificativ: *happy* și *energetic* domină datasetul (55% împreună), în timp ce *romantic* (117) și *calm* (246) sunt subreprezentate.

4.1.3 Normalizare

Feature-urile *loudness* (dB) și *tempo* (BPM) necesită normalizare la intervalul $[0, 1]$. Se utilizează **MinMaxScaler**:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (1)$$

Celelalte 6 feature-uri sunt deja în $[0, 1]$, dar sunt trecute prin scaler pentru consistență.

4.1.4 Împărțirea train/test

Datasetul se împarte în **80% train** / **20% test** cu stratificare pe coloana *mood_code*, asigurând reprezentarea proporțională a tuturor celor 8 mood-uri în ambele subseturi. Scaler-ul antrenat este salvat pentru utilizare în faza de recomandare.

4.2 Clasificare

4.2.1 Modele antrenate

S-au antrenat și comparat 3 clasificatori [5]:

1. **Decision Tree** – Adâncime maximă 8, ponderare automată a claselor (*class_weight="balanced"*)
2. **Random Forest** [8] – 200 estimatori, adâncime maximă 12, ponderare automată
3. **K-Nearest Neighbors (KNN)** [9] – $k = 7$ vecini

4.2.2 Rezultate

Tabela 4: Comparația modelelor de clasificare

Model	Acuratețe test	CV medie (5-fold)	CV std
Decision Tree	0.9940	0.9917	± 0.0021
Random Forest	0.9935	0.9915	± 0.0011
KNN	0.8605	0.8557	± 0.0089

Pentru a valida robustetea rezultatelor, s-a aplicat **5-fold cross-validation stratificat**. Deviația standard mică (≤ 0.009) confirmă că acuratețea este stabilă pe toate fold-urile, nu doar pe un split particular.

4.2.3 Metrici per clasă

Pentru a evalua impactul dezechilibrului de clasă, tabelul următor prezintă metricile detaliate pentru cel mai bun model (Decision Tree):

Tabela 5: Metrici per clasă – Decision Tree (test)

Mood	Suport	Precizie	Recall	F1
melancholic (0)	173	0.99	1.00	1.00
dark (1)	104	0.99	0.99	0.99
calm (2)	49	0.94	0.94	0.94
nostalgic (3)	158	0.99	0.97	0.98
romantic (4)	24	0.92	1.00	0.96
happy (5)	590	1.00	1.00	1.00
euphoric (6)	384	1.00	1.00	1.00
energetic (7)	518	1.00	1.00	1.00

Se observă că, deși clasele minoritare (*romantic*=24, *calm*=49) au suport redus, parametrul `class_weight="balanced"` menține precizia peste 92% și recall la 94–100%.

4.2.4 Analiza acurateții ridicate

Acuratețea de 99.40% provine din modul în care au fost generate labelurile pentru mood. Acestea au fost asignate **deterministic pe baza feature-urilor audio** (reguli pe valență, energie etc.). Clasificatorul învață în mod eficient aceleași reguli din date.

Validarea prin **5-fold cross-validation stratificat** confirmă că rezultatele sunt consistente, eliminând posibilitatea unui overfitting pe un anumit split.

4.3 Comparația supervizat vs. nesupervizat

În versiunile anterioare ale proiectului s-a comparat și abordarea nesupervizată (K-Means Clustering). Clusterele K-Means nu aliniau perfect cele 8 mood-uri, confirmând că etichetarea deterministă oferă o separare superioară.

5 Componenta de Reinforcement Learning

5.1 Formularea MDP

Problema generării unui playlist este formulată ca un **Proces Decizional Markov (MDP)** definit prin tuplul (S, A, T, R, γ) .

5.1.1 Spațiul stărilor

O stare este definită ca un triplet:

$$s = (\text{mood_curent}, \text{mood_tinta}, \text{bucket_pozitie}) \quad (2)$$

- **mood_curent** $\in \{0, 1, \dots, 7\}$ – mood-ul ultimei piese selectate;
- **mood_țintă** $\in \{0, 1, \dots, 7\}$ – mood-ul dorit de utilizator;
- **bucket_poziție** $\in \{0, 1, 2\}$ – segmentul playlist-ului (început, mijloc, final).

Spațiu total de stări: $|S| = 8 \times 8 \times 3 = 192$

5.1.2 Spațiul acțiunilor

O acțiune $a \in \{0, 1, \dots, 9\}$ reprezintă selecția unuia dintre cei 10 candidați din pool-ul de piese.

5.1.3 Funcția de recompensă

$$R(s, a) = \begin{cases} 1.0 & \text{dacă mood-ul piesei selectate} = \text{mood_țintă} \\ 0.5 & \text{dacă mood-ul piesei este adiacent mood-ului țintă} \\ 0.0 & \text{altfel} \end{cases} \quad (3)$$

5.2 Antrenarea Q-Learning

Algoritmul Q-Learning [3] actualizează o tabelă Q de dimensiune 192×10 folosind regula:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[R(s, a) + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (4)$$

Tabela 6: Hiperparametrii Q-Learning

Parametru	Simbol	Valoare
Rata de învățare	α	0.1
Factorul de discount	γ	0.95
Epsilon inițial	ϵ_0	1.0
Număr episoade	–	2 000

5.3 Învățare online prin feedback-ul utilizatorului

Am implementat un mecanism de **feedback online** (Like/Dislike) care actualizează Q-Table-ul în timp real:

$$Q(s, a) \leftarrow \begin{cases} Q(s, a) + \alpha \cdot (1.0 - Q(s, a)) & \text{dacă Like} \\ Q(s, a) - \alpha \cdot Q(s, a) & \text{dacă Dislike} \end{cases} \quad (5)$$

6 Integrarea componentelor și Interfața

Modulul `recommender.py` integrează similaritatea cosinus, clasificarea ML și selecția RL într-un pipeline unitar. Interfața grafică este construită în **Streamlit**, oferind generare interactivă, vizualizări prin grafice radar și management-ul conexiunii Spotify.

6.1 Integrarea cu Spotify

Aplicația oferă conectarea contului Spotify prin **OAuth 2.0 Authorization Code Flow**. Se extrag piesele salvate și de top pentru a genera un profil hibrid adaptat utilizatorului:

$$\text{profile}_{\text{blended}} = 0.6 \times \text{profile}_{\text{preset}} + 0.4 \times \text{profile}_{\text{user}} \quad (6)$$

De asemenea, este permis exportul direct al listei de piese în contul utilizatorului prin API.

7 Concluzii și direcții viitoare

Proiectul Musicon demonstrează integrarea cu succes a ML și RL pentru recomandarea muzicală bazată pe starea de spirit, oferind precizie ridicată de clasificare și adaptabilitate continuă prin feedback direct. Direcțiile viitoare includ utilizarea Deep Learning și a modelelor NLP avansate pentru descrierea textuală a mood-ului.

8 Bibliografie

Bibliografie

- [1] J. A. Russell, “A circumplex model of affect,” *J. Pers. Soc. Psychol.*, 1980.
- [2] R. E. Thayer, *The Biopsychology of Mood and Arousal*. 1989.
- [3] C. J. C. H. Watkins, “Q-learning,” *Mach. Learn.*, 1992.
- [4] R. S. Sutton, *Reinforcement Learning: An Introduction*. 2018.
- [5] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *JMLR*, 2011.
- [6] Streamlit Inc., <https://streamlit.io>, 2024.
- [7] Spotify, “Spotify Web API Reference,” 2024.
- [8] L. Breiman, “Random forests,” *Mach. Learn.*, 2001.

- [9] E. Fix, “Discriminatory analysis,” 1951.
- [10] C. C. Aggarwal, *Recommender Systems: The Textbook*. 2016.
- [11] S. Weiss, “Moodify – ML Hybrid Music Recommender System,” 2026.
- [12] Orzanai, “Moodify,” 2023.